

ESQUEMA

- 1) Carga de datos y exploración de estos
- 2) Normalización del valor a predecir

En el caso de datos numéricos y categóricos:

- 3) Selección de las variables que son de interés
- 4) Procesamos las variables numéricas y categóricas (normalización de datos)
- 5) Búsqueda y asignación de valores perdidos
- 6) Split de los datos
- 7) Generación del modelo (optimización del número de densas, el número de neuronas (recordar que construimos un encoder y por tanto, el número de neuronas se va reduciendo, ver que funciones de activación se utilizan, etc.)
- 8) Compilación del modelo (seleccionar funciones de pérdidas y optimizador junto con su `learning_rate`)
- 9) Entrenar y optimizar hiperparámetros

En el caso de las imágenes:

- 1) Normalizamos sus valores (normalmente se divide entre 255)
- 2) Split de los datos
- 3) Desarrollamos el modelo convolucional (tenemos varias opciones: fine-tuning, transfer learning o from scratch).
 - En primer lugar, probamos la técnica de transfer learning con algunas de las redes más conocidas (VGG, EfficientNet, Resnet). Como TOP model, siempre recomiendo usar GlobalMaxPooling/GlobalAveragePooling y una densa final con el número de neuronas igual al número de clases que clases si queremos resolver un problema de clasificación, solo una neurona si nos encontramos ante regresión. También, está la opción de poner Flatten y varias densas, reduciendo siempre el número de neuronas de las densas. No poner muchas densas en el top model ya que aumenta mucho el número de parámetros y por ello el overfitting.
 - Si no hay signos de overfitting, pasamos a la técnica de fine-tuning. Vamos descongelando bloques de detrás hacia delante. Empezamos con el último bloque convolucional, si vemos signos de overfitting entonces solo descongelamos las ultimas capas (en lugar de todo el bloque). Si no hay overfitting entonces podemos ir descongelando más bloques.
 - Por último, podemos hacer una comparación con una red from scratch. Para ello, diseñamos varios bloques convolucionales, vamos aumentando el número de filtros progresivamente. Normalmente, se suelen tener como mínimo unos tres bloques convolucionales.
- 4) Compilamos y entrenamos el modelo optimizando hiperparámetros. Evitamos overfitting con las técnicas que hemos visto (Dropout, max-pooling, regularización) etc que podemos ir introduciendo al modelo desarrollado anteriormente.